

Superresolución Espacial e Interpolación Temporal de Video CCTV con ESRGAN y RIFE

Jose Rodriguez Botello

Departamento de Electricidad y Electrónica
Universidad Francisco de Paula Santander
Cúcuta, Colombia
joseeliecerrb@ufps.edu.co

Sergio Castro Casadiego

Departamento de Electricidad y Electrónica
Universidad Francisco de Paula Santander
Cúcuta, Colombia
sergio.castroc@ufps.edu.co

Sebastian Rojas-Ortega

Department of Electrical and
Computer Engineering
University of Delaware
Newark, DE, USA
ortega@udel.edu

Abstract—Conventional video surveillance cameras often capture sequences with low spatial resolution and reduced frame rates, which hinders scene analysis and forensic tasks. This paper evaluates a deep learning pipeline for the spatial and temporal enhancement of surveillance video that combines two existing pretrained models: ESRGAN for spatial super-resolution and RIFE for temporal frame interpolation. The contribution is the integration of both stages and its evaluation on CCTV footage under a reproducible degradation protocol, rather than a new architecture. Footage recorded with a commercial fixed surveillance camera at 848×480 pixels and 15 fps was degraded to 212×120 pixels following the standard Real-ESRGAN synthetic protocol. The pipeline is evaluated using PSNR, SSIM, and LPIPS, a learned perceptual image quality metric, benchmarked against bicubic upscaling. ESRGAN reaches an LPIPS of 0.311 against 0.714 for bicubic upscaling, while its PSNR is lower, 18.84 dB against 20.42 dB, a behaviour consistent with the perception-distortion tradeoff. RIFE doubles the output frame rate from 15 to 30 fps, and its synthesized frames reach 37.12 dB in a hold-out test against 33.95 dB for frame averaging. The complete pipeline runs at 52.5 ms per input frame and 360 MB of GPU memory on a desktop card, which keeps it applicable to existing surveillance installations without replacing hardware.

Index Terms—Video surveillance, CCTV, super-resolution, frame interpolation, ESRGAN, RIFE, deep learning, image quality.

I. INTRODUCCIÓN

Los sistemas de videovigilancia constituyen un componente esencial para la seguridad en entornos residenciales, comerciales e industriales. No obstante, una proporción significativa de la infraestructura desplegada opera con equipos de bajo costo o con especificaciones originalmente diseñadas para anchos de banda y capacidades de almacenamiento reducidos, lo que produce secuencias de video con baja resolución espacial, ruido digital y deterioro visual severo bajo condiciones de iluminación adversas [1]. Estas limitaciones afectan directamente la capacidad de identificar personas, vehículos y objetos, reduciendo la efectividad del CCTV tanto en el monitoreo en tiempo real como en el análisis forense posterior al evento.

La mejora automática de video mediante aprendizaje profundo representa una alternativa viable para superar estas restricciones sin reemplazar la infraestructura instalada. En el dominio espacial, las redes convolucionales profundas aprenden a reconstruir texturas y bordes de alta frecuencia a partir de imágenes degradadas [2], [3]. Las redes generativas adversarias

(GAN) [4], y en particular SRGAN [5] y ESRGAN [6], han demostrado capacidad superior para sintetizar detalles fotorrealistas en comparación con los métodos de interpolación convencionales. En el dominio temporal, la interpolación de fotogramas mediante estimación de flujo óptico profundo [7], como Super SloMo [8], DAIN [9] y RIFE [10], genera fotogramas intermedios coherentes que aumentan la tasa de fotogramas y mejoran la continuidad visual.

Este artículo evalúa un flujo de trabajo secuencial que integra ESRGAN para la restauración espacial fotograma a fotograma y RIFE para la interpolación temporal entre fotogramas consecutivos, aplicado a secuencias de vigilancia degradadas a 212×120 píxeles mediante el protocolo sintético de Real-ESRGAN.

Conviene precisar el alcance de la contribución. Ambos modelos son preexistentes y se emplean con sus pesos preentrenados, sin modificar sus arquitecturas ni reentrenarlos. Lo que aporta este trabajo es la integración de las dos etapas en un solo flujo, su evaluación sobre grabaciones de una cámara de vigilancia comercial bajo un protocolo de degradación reproducible, y la medición del costo computacional que esa combinación impone en una GPU de escritorio. No se propone un algoritmo nuevo de superresolución ni de interpolación.

II. TRABAJOS RELACIONADOS

La mejora de la calidad en video de vigilancia involucra dos dimensiones complementarias: la superresolución espacial y la interpolación temporal. Ambas han sido abordadas extensamente de manera independiente; su integración en el contexto de los sistemas CCTV es, sin embargo, un área con menor desarrollo en la literatura.

II-A. Superresolución espacial

Los métodos clásicos de superresolución se basaron en interpolación matemática, como bicúbica y bilineal [3]. Aunque computacionalmente eficientes, estos enfoques promedian píxeles adyacentes sin modelar la distribución estadística de las texturas naturales, produciendo resultados visualmente suavizados incapaces de recuperar bordes y detalles finos.

El trabajo seminal de Dong et al. [2] demostró que una red neuronal convolucional (SRCNN) podía aprender el mapeo entre imágenes de baja y alta resolución, superando a los

métodos de interpolación en métricas objetivas. Posteriormente, las arquitecturas residuales [11] posibilitaron redes más profundas: EDSR [12] eliminó la normalización por lotes del generador, mientras que RCAN [13] incorporó mecanismos de atención sobre canales para ponderar de manera adaptativa las características de mayor relevancia espacial.

La introducción de las GAN [4] transformó el paradigma al añadir un discriminador que supervisa la calidad perceptual de las imágenes generadas. SRGAN [5] fue el primer modelo en aplicar este esquema a SR de factor $\times 4$, complementado por una función de pérdida perceptual basada en activaciones de VGG [14], propuesta inicialmente por Johnson et al. [15]. ESRGAN [6] extendió esta arquitectura con bloques RRDB, un discriminador relativista y una pérdida perceptual mejorada, logrando texturas fotorrealistas superiores. Real-ESRGAN [16] adaptó el modelo para degradaciones del mundo real mediante datos de entrenamiento sintéticos complejos, lo que lo hace especialmente adecuado para el procesamiento de secuencias de baja calidad propias de los sistemas CCTV.

II-B. Superresolución de video

La superresolución de video (VSR) explota la redundancia temporal entre fotogramas consecutivos para obtener reconstrucciones de mayor calidad que la SR sobre imágenes estáticas. EDVR [17] introdujo redes de alineación y fusión con convoluciones deformables, alineando fotogramas vecinos en el espacio de características antes de la fusión. BasicVSR [18] identificó la propagación bidireccional de características a lo largo de la secuencia como componente esencial, logrando un balance superior entre rendimiento y eficiencia computacional. Estos modelos, no obstante, requieren el procesamiento conjunto de múltiples fotogramas, lo que introduce latencia y demanda de memoria que puede ser prohibitiva en sistemas de vigilancia con recursos limitados.

II-C. Interpolación temporal de fotogramas

La estimación del flujo óptico mediante redes profundas, introducida con FlowNet [7], permitió calcular desplazamientos densos entre fotogramas de manera diferenciable. Super Slo-Mo [8] generalizó este enfoque para la síntesis de múltiples fotogramas intermedios mediante flujos ópticos bidireccionales. DAIN [9] incorporó estimaciones de profundidad de la escena para mejorar la interpolación en regiones de oclusión, obteniendo resultados visualmente más coherentes en secuencias con movimientos complejos. RIFE [10] simplificó la arquitectura mediante IFNet, que estima el flujo intermedio de manera directa sin descomposición bidireccional, y aplica destilación de conocimiento [19] para un entrenamiento eficiente, logrando interpolación en tiempo real con calidad competitiva.

II-D. Posicionamiento del presente trabajo

A pesar del progreso individual en SR espacial e interpolación temporal, la mayoría de los métodos abordan una sola dimensión de mejora. Los sistemas CCTV de bajo costo presentan simultáneamente deficiencias en resolución y en tasa de fotogramas, por lo que mejorar solo una de estas

dimensiones deja sin resolver una parte sustancial del problema. El presente trabajo integra ESRGAN [6] y RIFE [10] en un flujo secuencial orientado a las restricciones reales de estos sistemas, y lo caracteriza tanto en calidad de imagen como en costo de cómputo.

III. METODOLOGÍA

Se diseñó un flujo de trabajo secuencial que procesa cada secuencia de video degradada a través de cuatro etapas aplicadas a nivel de fotograma individual. La combinación de mejora espacial y síntesis temporal permite recuperar simultáneamente la resolución y la fluidez del video de entrada.

III-A. Adquisición y Preparación del Conjunto de Datos

La evaluación se realizó sobre una grabación propia, capturada con una cámara de vigilancia comercial EZVIZ instalada en posición fija sobre una vía urbana, en horario diurno, a 15 fps y con resolución nativa de 848×480 píxeles. Esta grabación cumple la función de referencia de alta resolución (HR).

Para simular las degradaciones de los sistemas CCTV de menor calidad se aplicó el protocolo de degradación sintética de Real-ESRGAN [16]: difuminado gaussiano ($\sigma = 1.5$), remuestreo bicúbico descendente con factor $4\times$, compresión JPEG (calidad 50) y ruido gaussiano aditivo ($\sigma = 5$ DN). El protocolo reduce los fotogramas HR de 848×480 a imágenes de baja resolución (LR) de 212×120 píxeles, generando artefactos representativos de cámaras de baja gama. Se emplearon 60 fotogramas para la evaluación cuantitativa.

III-B. Arquitectura del Flujo de Trabajo

El procesamiento de cada secuencia sigue cuatro etapas secuenciales, ilustradas en la Fig. 1:

1. **Extracción de fotogramas:** El video de entrada se descompone en fotogramas individuales. Para la evaluación cuantitativa se tomaron 60 fotogramas repartidos de manera uniforme a lo largo de la grabación, de modo que la medición no quede concentrada en un único instante de la escena. La evaluación temporal, en cambio, requiere fotogramas contiguos y se realizó sobre tramos consecutivos del video.
2. **Superresolución espacial:** Cada fotograma LR se procesa individualmente mediante ESRGAN [6], cuya arquitectura se detalla en la Fig. 2. La red reconstruye las texturas y eleva la resolución por un factor de $4\times$, produciendo fotogramas de 848×480 píxeles.
3. **Interpolación temporal:** La secuencia de fotogramas mejorados se transfiere al modelo RIFE [10], descrito en la Fig. 3, que estima el flujo óptico entre fotogramas consecutivos y sintetiza un fotograma intermedio por cada par, incrementando la tasa de captura en un factor de $2\times$.
4. **Reconstrucción del video:** Los fotogramas mejorados y los fotogramas sintetizados se ensamblan en orden cronológico para producir el video de salida con mayor resolución y movimiento fluido.




Fig. 1. Flujo de trabajo propuesto para la mejora de video CCTV en resolución y fluidez.




Fig. 2. Arquitectura de ESRGAN [6]. El generador encadena una convolución inicial, 23 bloques RRDB con conexión residual global, la etapa de muestreo ascendente $\times 4$ y una convolución final. Las tres funciones de pérdida solo intervienen durante el entrenamiento; en inferencia se ejecuta únicamente el generador.

III-C. Entorno de Implementación

El flujo se implementó en Python 3.11 sobre una GPU NVIDIA RTX 4070 Ti (12 GB VRAM, CUDA 12.4). Las librerías principales empleadas son *realrgan* 0.3 para la inferencia de ESRGAN y el repositorio oficial ECCV2022-RIFE [10] para la interpolación temporal.

III-D. Modelos de Inteligencia Artificial Empleados

III-D1. ESRGAN: ESRGAN (Enhanced Super-Resolution Generative Adversarial Network) [6] es una red generativa adversaria [4] entrenada con funciones de pérdida perceptuales para reconstruir detalles de alta frecuencia a partir de imágenes degradadas. A diferencia de su predecesor SRGAN [5], su generador utiliza bloques densos residuales en cascada (RRDB) derivados de las redes residuales [11], eliminando las capas de normalización por lotes para evitar los artefactos que estas introducen en la síntesis de texturas. Un discriminador relativista promedio (RaD) evalúa si una imagen real es perceptualmente superior a una generada, incentivando la producción de texturas realistas. La función de pérdida combina error a nivel de píxel (L_1), pérdida adversarial y pérdida perceptual derivada de activaciones de VGG [14], originalmente propuesta por Johnson et al. [15]. La Fig. 2 resume el generador y las tres funciones de pérdida. En este trabajo se emplean los pesos preentrenados de Real-ESRGAN sin reentrenamiento, por lo que durante la inferencia solo se ejecuta el generador.

III-D2. RIFE: RIFE (Real-time Intermediate Flow Estimation) [10] es un modelo de interpolación de fotogramas que estima directamente el flujo óptico intermedio entre dos fotogramas consecutivos, sin recurrir a la descomposición bidireccional empleada por métodos anteriores como DAIN [9] y Super SloMo [8]. Su componente central, IFNet, calcula este flujo a múltiples escalas de resolución de manera progresiva.




Fig. 3. Arquitectura de RIFE [10]. IFNet estima el flujo intermedio entre los dos fotogramas de entrada, que se usa para deformarlos hacia el instante $t+0.5$; la etapa de fusión combina ambas versiones deformadas y corrige las regiones de oclusión. Las líneas discontinuas indican los fotogramas de entrada que alimentan la deformación.

Un esquema de destilación de conocimiento [19] guía el entrenamiento de IFNet, permitiéndole aprender representaciones de movimiento precisas de manera eficiente. El fotograma intermedio se reconstruye aplicando deformación espacial (*warping*) sobre los fotogramas adyacentes, ponderada por el flujo estimado, seguida de una etapa de fusión que corrige inconsistencias en regiones de oclusión, tal como se esquematiza en la Fig. 3.

IV. RESULTADOS EXPERIMENTALES

El flujo propuesto se evaluó sobre la grabación descrita en la Sección III-A en tres frentes: la reconstrucción visual, la calidad de los fotogramas que aporta la interpolación temporal, y las métricas objetivas frente al escalado bicúbico.

IV-A. Evaluación Cualitativa

La Fig. 4 presenta cuatro versiones del mismo fotograma: la entrada LR (212×120 px, escalada por vecino más próximo), el escalado bicúbico $\times 4$, la salida de ESRGAN $\times 4$ y la referencia HR (848×480 px). La recuperación de nitidez en bordes y definición de texturas es apreciable en las regiones de interés relevantes para la identificación de personas y objetos.

IV-B. Análisis de Detalle

La Fig. 5 presenta, para una región de interés, la entrada LR escalada, la reconstrucción bicúbica, la salida de ESRGAN y la referencia HR, tanto en los fotogramas completos (fila superior) como en parches ampliados (fila inferior). La diferencia entre métodos evidencia que ESRGAN recupera bordes y texturas de alta frecuencia que la interpolación bicúbica, al promediar píxeles, no puede restituir.

IV-C. Evaluación de Fluidez Temporal

La incorporación de RIFE duplica la tasa de fotogramas de 15 a 30 fps. La Fig. 6 muestra un par de fotogramas contiguos de la secuencia, separados 66.7 ms, junto al fotograma que RIFE sintetiza entre ambos.

Los fotogramas sintetizados no tienen referencia con la cual compararse, ya que se insertan en instantes que la cámara no registró. Para medir su calidad se recurrió a una prueba de exclusión: de tripletes consecutivos ($t-1, t, t+1$) de la



Fig. 4. Comparación de métodos sobre un fotograma representativo: entrada LR (212×120 , escalada por vecino más próximo), reconstrucción bicúbica $\times 4$, salida de ESRGAN $\times 4$ (propuesto) y referencia HR (848×480). Los valores de PSNR, SSIM y LPIPS indicados sobre los dos métodos comparados son los promedios de los 60 fotogramas de evaluación, no los de este fotograma en particular.




Fig. 5. Análisis de detalle: fila superior, fotogramas completos con la región de interés marcada en rojo (entrada LR escalada, bicúbico, ESRGAN y referencia HR); fila inferior, parches ampliados de dicha región. ESRGAN recupera contornos y texturas de alta frecuencia ausentes en la reconstrucción bicúbica.

grabación original se ocultó el fotograma central, se interpoló a partir de los dos extremos y el resultado se comparó con el fotograma real. La prueba se restringió a los tripletes con movimiento apreciable, medidos como una diferencia absoluta media superior a 3 DN entre los dos extremos, porque en los tramos estáticos cualquier método reproduce el fotograma oculto y la comparación pierde sentido. Sobre 23 tripletes así seleccionados, RIFE obtuvo 37.12 dB de PSNR, 0.9836 de SSIM y 0.0111 de LPIPS, frente a 33.95 dB, 0.9759 y 0.0161 del promediado de los dos fotogramas vecinos. Conviene señalar que la prueba es más exigente que el uso real: los dos extremos del triplete están separados por dos intervalos de captura, mientras que en el flujo propuesto la interpolación ocurre entre fotogramas separados por uno solo.

IV-D. Evaluación Cuantitativa

La calidad objetiva de la mejora espacial se midió mediante PSNR (*Peak Signal-to-Noise Ratio*) y SSIM (*Structural Similarity Index*). El PSNR cuantifica la relación entre la potencia máxima de la señal y el error de reconstrucción [20]:

$$\text{PSNR} = 10 \log_{10} \frac{\text{MAX}_I^2}{\text{MSE}} \quad (1)$$

donde MAX_I es el valor máximo posible de un píxel y MSE el error cuadrático medio entre la imagen de referencia y la reconstruida.

El SSIM evalúa la similitud estructural entre imágenes considerando luminosidad, contraste y estructura de manera conjunta [21]:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)} \quad (2)$$

donde μ denota la media, σ_{xy} la covarianza, y c_1, c_2 constantes de estabilización.

La Tabla I resume los resultados promedio sobre los 60 fotogramas de evaluación, junto con el costo computacional de cada método. La columna de fps de salida es la tasa del video resultante, distinta de la velocidad de procesamiento que recoge la última columna. Las tres métricas espaciales se calculan siempre sobre los fotogramas presentes en la secuencia original,



Fig. 6. Interpolación temporal con RIFE sobre dos fotogramas contiguos de la secuencia, separados 66.7 ms: salida de ESRGAN en t , fotograma sintetizado en $t+0.5$ y salida de ESRGAN en $t+1$. El fotograma intermedio sitúa los objetos en movimiento en una posición coherente con la de los dos fotogramas reales.

Tabla I
CALIDAD OBJETIVA Y COSTO COMPUTACIONAL

Método	PSNR↑	SSIM↑	LPIPS↓	fps sal.	ms/fot.
Bicúbica $\times 4$	20.42	0.5132	0.7140	15	0.5
ESRGAN $\times 4$	18.84	0.5194	0.3112	15	45.5
ESRGAN + RIFE (propuesto)	18.84	0.5194	0.3112	30	52.5

que son los únicos que tienen referencia HR; por eso ESRGAN y el flujo completo comparten esos valores y se diferencian en la tasa de salida y en el tiempo de procesamiento. La calidad de los fotogramas añadidos por RIFE se reporta por separado en la Sección IV-C.

V. DISCUSIÓN

Los resultados muestran que ESRGAN y RIFE abordan de manera complementaria las dos principales deficiencias de los sistemas CCTV de bajo costo. Mientras que los métodos de interpolación matemática, como la bicúbica [3], calculan píxeles por promediado local sin recuperar información espectral de alta frecuencia, el generador RRDB de ESRGAN [6] sintetiza detalles estructurales a partir de representaciones latentes, produciendo bordes nítidos y texturas perceptualmente coherentes. Esta ventaja es especialmente relevante en secuencias de vigilancia donde el reconocimiento de rostros, matrículas vehiculares e indumentaria puede ser determinante en investigaciones forenses.

Como se aprecia en la Tabla I, ESRGAN obtiene un PSNR de 18.84 dB frente a 20.42 dB del escalado bicúbico, resultado consistente con la brecha percepción-distorsión documentada por Blau y Michaeli [22]: los modelos generativos sacrifican fidelidad píxel a píxel a favor de la calidad perceptual. Esta interpretación queda respaldada por el índice LPIPS [23], que evalúa la similitud perceptual mediante activaciones de redes neuronales profundas: ESRGAN alcanza un LPIPS de 0.311 frente a 0.714 del escalado bicúbico, una reducción del 56 % que refleja la capacidad del modelo para sintetizar estructuras visualmente coherentes que el promediado local de la bicúbica no puede recuperar. El índice SSIM presenta una diferencia marginal (0.5194 frente a 0.5132), lo que indica que la mejora del generador se concentra principalmente en detalles de alta

frecuencia cuya contribución a la distorsión estructural global es limitada.

En el dominio temporal, IFNet estima el flujo óptico intermedio de manera directa, estrategia que en estudios previos de interpolación [8], [9] ha mostrado producir transiciones más suaves y coherentes que el promediado simple de fotogramas. La mayor tasa de fotogramas resultante mejora la representación continua del movimiento y facilita el seguimiento de objetos por parte de operadores y algoritmos de análisis de video.

En cuanto al costo computacional, ESRGAN tarda 45.5 ms por fotograma y RIFE 14.0 ms por cada fotograma sintetizado, medidos sobre la GPU RTX 4070 Ti con el modelo ya cargado en memoria. Como RIFE genera un fotograma por cada par de entrada, el flujo completo consume 52.5 ms por fotograma de entrada, es decir que procesa 19.0 fotogramas de entrada por segundo. El pico de memoria de video es de 360 MB para ESRGAN y 274 MB para RIFE; como las etapas se ejecutan una después de la otra, el pico del flujo completo es el mayor de los dos y no su suma. El sistema procesa por tanto una cámara de 15 fps en tiempo real sobre una GPU de escritorio, sin necesidad de infraestructura en la nube, aunque el margen que queda es estrecho para atender varias cámaras en paralelo con el mismo equipo.

Los resultados anteriores deben leerse considerando el alcance de las pruebas. La evaluación cuantitativa se apoya en 60 fotogramas de una sola escena exterior diurna, un conjunto suficiente para observar la tendencia entre métodos pero demasiado reducido para sostener conclusiones sobre el comportamiento del sistema en condiciones distintas. Falta en particular material nocturno e interior, donde el ruido del sensor y la iluminación artificial cambian de manera notable las degradaciones presentes. La degradación además se generó con un único protocolo sintético de parámetros fijos, mientras que las cámaras reales combinan desenfoque de movimiento, artefactos de compresión variables según el códec y pérdidas de transmisión; probar con degradaciones más diversas es necesario para estimar la robustez del sistema. A esto se suma que ESRGAN procesa cada fotograma de forma independiente, sin usar información de los fotogramas vecinos, lo que puede producir variaciones de textura entre fotogramas contiguos en las zonas donde la red sintetiza detalle. Por último, RIFE

es sensible a los cambios de iluminación abruptos y a los movimientos muy rápidos, donde pueden aparecer halos o transiciones no naturales en los bordes de los objetos.

VI. CONCLUSIONES Y TRABAJOS FUTUROS

VI-A. Conclusiones

Se evaluó un flujo de mejora de video en resolución y fluidez para sistemas CCTV, basado en la integración secuencial de ESRGAN [6] ($4\times$ superresolución espacial) y RIFE [10] ($2\times$ interpolación temporal), sobre secuencias degradadas a 212×120 píxeles mediante el protocolo sintético de Real-ESRGAN [16]. La contribución no es un modelo nuevo, sino la combinación de dos modelos preentrenados en un solo flujo y su caracterización sobre grabaciones de una cámara de vigilancia comercial, tanto en calidad de imagen como en costo de cómputo.

La evaluación cuantitativa sobre 60 fotogramas muestra que ESRGAN obtiene un LPIPS de 0.311 frente a 0.714 del escalado bicúbico, una reducción del 56 %, con una diferencia de SSIM marginal (0.5194 frente a 0.5132) y un PSNR inferior, 18.84 dB frente a 20.42 dB. Este comportamiento es consistente con la brecha percepción-distorsión [22]: el generador sacrifica fidelidad píxel a píxel para producir texturas visualmente coherentes que la bicúbica no recupera. En el dominio temporal, la prueba de exclusión sobre 23 tripletes con movimiento sitúa los fotogramas sintetizados por RIFE en 37.12 dB frente a 33.95 dB del promediado de vecinos. El flujo completo se ejecuta en 52.5 ms por fotograma de entrada, con un pico de 360 MB de memoria de video en una GPU de escritorio, lo que permite sostener la tasa de captura de la cámara sin recurrir a infraestructura externa. Los resultados se obtuvieron sobre una única escena diurna, por lo que constituyen una caracterización inicial y no una validación en condiciones variadas de operación.

VI-B. Trabajos Futuros

La prioridad inmediata es ampliar el conjunto de evaluación a escenas nocturnas e interiores y a degradaciones más variadas que el protocolo sintético empleado, de modo que las cifras reportadas puedan contrastarse en condiciones de operación diferentes. En segundo lugar, se explorará la incorporación de técnicas de superresolución de video como BasicVSR [18], que aprovechan la coherencia entre fotogramas vecinos y podrían atenuar las variaciones de textura que introduce el procesamiento fotograma a fotograma. Finalmente, se plantea integrar un módulo de detección de eventos que active la mejora de resolución solo sobre los segmentos de interés, lo que reduciría la carga de cómputo y haría viable atender varias cámaras con un mismo equipo, así como la optimización del flujo para hardware embebido.

REFERENCIAS

- [1] J. Li, L. Huang, and C. Liu, "Robust people counting in video surveillance: Dataset and system," in *2011 8th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS)*, 2011, pp. 54–59.
- [2] C. Dong, C. C. Loy, K. He, and X. Tang, "Learning a deep convolutional network for image super-resolution," in *European Conference on Computer Vision (ECCV)*, 2014, pp. 184–199.
- [3] J. D. van Ouwerkerk, "Image super-resolution survey," *Image and Vision Computing*, vol. 24, no. 10, pp. 1039–1052, Oct. 2006.
- [4] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative adversarial nets," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 2672–2680.
- [5] C. Ledig, L. Theis, F. Huszár, J. Caballero, A. Cunningham, A. Acosta, A. Aitken, A. Tejani, J. Totz, Z. Wang, and W. Shi, "Photo-realistic single image super-resolution using a generative adversarial network," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 105–114.
- [6] X. Wang, K. Yu, S. Wu, J. Gu, Y. Liu, C. Dong, Y. Qiao, and C. C. Loy, "ESRGAN: Enhanced super-resolution generative adversarial networks," in *European Conference on Computer Vision (ECCV) Workshops*, 2018, pp. 63–79.
- [7] A. Dosovitskiy, P. Fischer, E. Ilg, P. Häusser, C. Hazirbas, V. Golkov, P. van der Smagt, D. Cremers, and T. Brox, "FlowNet: Learning optical flow with convolutional networks," in *IEEE International Conference on Computer Vision (ICCV)*, 2015, pp. 2758–2766.
- [8] H. Jiang, D. Sun, V. Jampani, M.-H. Yang, E. Learned-Miller, and J. Kautz, "Super SloMo: High quality estimation of multiple intermediate frames for video interpolation," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 9000–9008.
- [9] W. Bao, W.-S. Lai, C. Ma, X. Zhang, Z. Gao, and M.-H. Yang, "Depth-aware video frame interpolation," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 3703–3712.
- [10] Z. Huang, T. Zhang, W. Heng, B. Shi, and S. Zhou, "Real-time intermediate flow estimation for video frame interpolation," in *European Conference on Computer Vision (ECCV)*, 2022, pp. 624–642.
- [11] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [12] B. Lim, S. Son, H. Kim, S. Nah, and K. M. Lee, "Enhanced deep residual networks for single image super-resolution," in *IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2017, pp. 1132–1140.
- [13] Y. Zhang, K. Li, K. Li, L. Wang, B. Zhong, and Y. Fu, "Image super-resolution using very deep residual channel attention networks," in *European Conference on Computer Vision (ECCV)*, 2018, pp. 294–310.
- [14] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," in *International Conference on Learning Representations (ICLR)*, 2015.
- [15] J. Johnson, A. Alahi, and L. Fei-Fei, "Perceptual losses for real-time style transfer and super-resolution," in *European Conference on Computer Vision (ECCV)*, 2016, pp. 694–711.
- [16] X. Wang, L. Xie, C. Dong, and Y. Shan, "Real-ESRGAN: Training real-world blind super-resolution with pure synthetic data," in *IEEE International Conference on Computer Vision Workshops (ICCVW)*, 2021, pp. 1905–1914.
- [17] X. Wang, K. C. K. Chan, K. Yu, C. Dong, and C. C. Loy, "EDVR: Video restoration with enhanced deformable convolutional networks," in *IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2019, pp. 1954–1963.
- [18] K. C. K. Chan, X. Wang, K. Yu, C. Dong, and C. C. Loy, "BasicVSR: The search for essential components in video super-resolution and beyond," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 4947–4956.
- [19] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," arXiv preprint arXiv:1503.02531, 2015.
- [20] Q. Huynh-Thu and M. Ghanbari, "Scope of validity of PSNR in image/video quality assessment," *Electronics Letters*, vol. 44, no. 13, pp. 800–801, 2008.
- [21] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: From error visibility to structural similarity," *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, Apr. 2004.
- [22] Y. Blau and T. Michaeli, "The perception-distortion tradeoff," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 6228–6237.
- [23] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 586–595.