

DESARROLLO DE UN MODELO DE INTELIGENCIA ARTIFICIAL PARA EL  
ESCALAMIENTO VISUAL EN VIDEOVIGILANCIA MEDIANTE TÉCNICAS DE  
SUPERRESOLUCIÓN Y TRANSFORMADORES VISUALES

Presentado por:

JOSE ELIECER RODRIGUEZ BOTELLO

UNIVERSIDAD FRANCISCO DE PAULA SANTANDER

FACULTAD DE INGENIERÍA

INGENIERÍA ELECTRÓNICA

SAN JOSÉ DE CÚCUTA

2025

DESARROLLO DE UN MODELO DE INTELIGENCIA ARTIFICIAL PARA EL  
ESCALAMIENTO VISUAL EN VIDEOVIGILANCIA MEDIANTE TÉCNICAS DE  
SUPERRESOLUCIÓN Y TRANSFORMADORES VISUALES

Anteproyecto de grado para optar por el título de:

INGENIERO ELECTRÓNICO

Modalidad: Investigación

Presentado por:

JOSE ELIECER RODRIGUEZ BOTELLO

Código: 1161618

Director:

Ph.D. SERGIO ALEXANDER CASTRO CASADIEGO

Codirector:

Ph.D. (c). SEBASTIAN ROJAS ORTEGA

UNIVERSIDAD FRANCISCO DE PAULA SANTANDER

FACULTAD DE INGENIERÍA

INGENIERÍA ELECTRÓNICA

SAN JOSÉ DE CÚCUTA

2025

| Tabla de Contenido                    | Pág                                  |
|---------------------------------------|--------------------------------------|
| Introducción .....                    | 8                                    |
| 1. Descripción del problema.....      | 9                                    |
| 1.1 Planteamiento del problema .....  | 9                                    |
| 1.2 Justificación.....                | 11                                   |
| 1.2.1 Beneficios tecnológicos.....    | 12                                   |
| 1.2.2 Beneficios económicos.....      | 12                                   |
| 1.2.3 Beneficios sociales .....       | 12                                   |
| 1.2.4 Beneficios institucionales..... | 13                                   |
| 1.3 Alcances .....                    | 13                                   |
| 1.3.1 Resultados esperados.....       | <b>¡Error! Marcador no definido.</b> |
| 1.4 Limitaciones .....                | 14                                   |
| 1.4.1 Limitaciones de hardware .....  | <b>¡Error! Marcador no definido.</b> |
| 1.5 Delimitaciones.....               | <b>¡Error! Marcador no definido.</b> |
| 1.5.1 Conceptual.....                 | <b>¡Error! Marcador no definido.</b> |
| 1.5.2 Espacial .....                  | <b>¡Error! Marcador no definido.</b> |
| 1.5.3 Temporal .....                  | <b>¡Error! Marcador no definido.</b> |
| 2. Objetivos .....                    | 15                                   |
| 2.1 Objetivo General .....            | 15                                   |
| 2.2 Objetivos Específicos .....       | 15                                   |

|                                                               |    |
|---------------------------------------------------------------|----|
| 3. Marco Referencial.....                                     | 16 |
| 3.1 Antecedentes .....                                        | 16 |
| 3.1.1 Referentes regionales .....                             | 16 |
| 3.1.2 Referentes nacionales .....                             | 17 |
| 3.1.2 Referentes internacionales.....                         | 19 |
| 3.2 Marco Teórico .....                                       | 22 |
| 3.2.1 Inteligencia Artificial .....                           | 22 |
| 3.2.1.1 Redes neuronales.....                                 | 22 |
| 3.2.1.2 Transformadores visuales.....                         | 23 |
| 3.2.1.3 Aprendizaje profundo (Deep Learning) .....            | 23 |
| 3.2.2 Procesamiento de imágenes .....                         | 24 |
| 3.2.2.1 Superresolución .....                                 | 24 |
| 3.2.2.2 GAN.....                                              | 24 |
| 3.2.2.3 SRGAN .....                                           | 25 |
| 3.2.2.4 ESRGAN.....                                           | 26 |
| 3.2.3 Interpolación de fotogramas (Frame Interpolation) ..... | 26 |
| 3.2.3.1 RIFE (Real Time Intermediate Flow Estimation) .....   | 27 |
| 3.2.4 Google Colab.....                                       | 27 |
| 3.2.5 Validación y métricas .....                             | 27 |
| 3.2.5.1 PSNR (Peak Signal to Noise Ratio) .....               | 28 |

|                                                                                      |                                      |
|--------------------------------------------------------------------------------------|--------------------------------------|
| 3.2.5.2 SSIM (Structural Similarity Index Measure) .....                             | 28                                   |
| 3.3 Marco Legal .....                                                                | 28                                   |
| 3.3.1 Ley 603 de 2000: Distribución de Licencias y Derechos de Autor .....           | 29                                   |
| 3.3.2 Ley 1273 de 2009: Manipulación de Bases de Datos en Sistemas Informáticos .... | 29                                   |
| 3.3.3 Ley 23 de 1982: Ley de Protección de los Derechos de Autor .....               | 29                                   |
| 3.3.4 Ley 1581 de 2012: Protección de Datos Personales / Habeas Data .....           | 30                                   |
| 3.3.5 Ley 1801 de 2016: Código de Policía .....                                      | 30                                   |
| 4. Diseño Metodológico .....                                                         | 31                                   |
| 4.1 Selección de los datos .....                                                     | 32                                   |
| 4.2 Caracterización de los datos .....                                               | 33                                   |
| 4.3 Definición de entradas y salidas .....                                           | 35                                   |
| 4.4 Implementación del modelo .....                                                  | <b>¡Error! Marcador no definido.</b> |
| 4.5 Evaluación del software .....                                                    | <b>¡Error! Marcador no definido.</b> |
| 5. Cronograma .....                                                                  | <b>¡Error! Marcador no definido.</b> |
| 6. Presupuesto .....                                                                 | <b>¡Error! Marcador no definido.</b> |
| Referencias .....                                                                    | 37                                   |

## Lista de Tablas

Pág

|                                                                                                   |                                      |
|---------------------------------------------------------------------------------------------------|--------------------------------------|
| Tabla 1. Normativa sobre la creación de algoritmos en Colombia. ....                              | 29                                   |
| Tabla 2. Cronograma de actividades del primer mes al sexto mes. ....                              | <b>¡Error! Marcador no definido.</b> |
| Tabla 3. Cronograma de actividades del séptimo mes al doceavo mes. ..                             | <b>¡Error! Marcador no definido.</b> |
| Tabla 4. Presupuesto global del proyecto por fuentes de financiación (en miles de COP).<br>.....  | <b>¡Error! Marcador no definido.</b> |
| Tabla 5. Descripción de los gastos de personal (en miles de COP). ....                            | <b>¡Error! Marcador no definido.</b> |
| Tabla 6. Descripción de los equipos que se planea adquirir o arrendar (en miles de COP).<br>..... | <b>¡Error! Marcador no definido.</b> |
| Tabla 7. Descripción del software que se planea adquirir o licenciar (en miles de COP).<br>.....  | <b>¡Error! Marcador no definido.</b> |
| Tabla 8. Material bibliográfico (en miles de COP). ....                                           | <b>¡Error! Marcador no definido.</b> |

## **Lista de Figuras**

**Pág**

|                                                                       |    |
|-----------------------------------------------------------------------|----|
| Figura 1. Esquema de una red neuronal artificial. Tomado de [17]..... | 23 |
| Figura 2. Ruta de actividades. Fuente: Elaboración propia.....        | 31 |

## **Introducción**

En la actualidad, las cámaras de videovigilancia se han convertido en una herramienta fundamental para la seguridad en entornos laborales, comerciales y residenciales. Sin embargo, muchas de estas cámaras operan con hardware limitado y/o de bajo costo, lo que se traduce en videos de baja calidad, con resolución deficiente, ruido digital y problemas que se derivan a partir de malas condiciones de iluminación. Estas limitaciones dificultan la identificación precisa de personas u objetos, reduciendo la efectividad de los sistemas de seguridad.

Ante este panorama, los avances en inteligencia artificial (IA) han abierto nuevas posibilidades para el mejoramiento automático de la calidad de imagen y video. Una de las técnicas prometedoras es la superresolución, que permite aumentar la resolución de imágenes y videos a partir de fuentes de baja calidad. Esto combinado con transformadores visuales, que son modelos capaces de aprender patrones complejos en los datos visuales [1]. Esta técnica también puede aplicarse para mejorar la fluidez del video mediante el aumento de fotogramas por segundo, generando cuadros intermedios y optimizando la continuidad visual [2].

Este anteproyecto plantea el desarrollo de un modelo de IA basado en técnicas de superresolución y transformadores visuales, con el objetivo de mejorar tanto la resolución como la fluidez de los videos capturados por cámaras de seguridad, incrementando así su utilidad para el análisis y reconocimiento en entornos de videovigilancia.



## **1. Descripción del problema**

Actualmente, una de las herramientas muy comunes pero efectivas para asegurar la seguridad en distintos espacios, públicos y privados, son las cámaras de videovigilancia. La mayoría de los dispositivos de videovigilancia presentan ciertas limitaciones de hardware debido a las cuales puede aparecer baja resolución, ruido, iluminación insuficiente y otra serie de problemas cuando se enfrentan con ciertas condiciones. Uno de los factores que contribuyen es el costo mínimo de la mayoría de las cámaras al consumidor promedio [3]. Como consecuencia, en casos de hechos de delincuencia, la baja calidad de imagen hace que se impida la identificación detallada de las personas u objetos, limitando el valor probatorio del material audiovisual.

Ante esta problemática, las herramientas basadas en inteligencia artificial pueden ofrecer soluciones como lo es la superresolución y el aumento de fotogramas por segundo, que permiten mejorar tanto la calidad como la fluidez de los videos capturados por estas cámaras de vigilancia.

### **1.1 Planteamiento del problema**

A pesar de la creciente instalación de cámaras de videovigilancia en espacios públicos y privados, persiste una problemática crítica: muchos de estos dispositivos generan videos con baja calidad de imagen, escaso nivel de detalle y dificultades para operar adecuadamente en condiciones de poca iluminación. Esta deficiencia tecnológica representa una vulnerabilidad en los sistemas de seguridad, que puede ser aprovechada por actores delincuenciales para evadir la identificación o el seguimiento de sus acciones [4].

Curiosamente, los teléfonos móviles actuales suelen ofrecer capacidades de grabación de video superiores en términos de resolución y detalle. Aunque se tenga mejor calidad en los videos por estos dispositivos no están diseñados para fines de seguridad, ya que su enfoque es la captura de momentos cotidianos, y no siempre cuentan con sensores óptimos para operar en

condiciones nocturnas. Por su parte, las cámaras de seguridad sí integran tecnologías como sensores infrarrojos, pero aun así presentan limitaciones en cuanto a calidad visual, especialmente en sistemas de bajo costo.

Este desfase entre la tecnología que integra la cámara de seguridad y la calidad del video plantea la necesidad de implementar tecnologías complementarias que mejoren el desempeño de las cámaras de seguridad existentes. En particular, el uso de inteligencia artificial permite abordar estas limitaciones a través de técnicas como la superresolución y la generación de fotogramas intermedios, que optimizan tanto la resolución como la fluidez de los videos capturados, aumentando su valor para la seguridad y vigilancia.

Actualmente, muchas personas optan por adquirir cámaras de videovigilancia de bajo costo, priorizando la accesibilidad económica por encima de la calidad del equipo. Esta elección suele estar motivada por la intención de disuadir actos delictivos, más que por la necesidad de contar con registros visuales de alta fidelidad. Incluso quienes ya disponen de estos sistemas frecuentemente enfrentan limitaciones técnicas, como grabaciones de baja resolución, mala iluminación, ángulos inadecuados o falta de mantenimiento y actualizaciones, debido también a restricciones económicas [5]. Estas deficiencias impactan directamente en la utilidad de las grabaciones como material probatorio. En ocasiones, cuando las autoridades solicitan estos videos como evidencia de un hecho delictivo, la baja calidad impide la identificación precisa de los involucrados. No obstante, este tipo de material tiene un valor potencial crucial, ya que puede permitir el reconocimiento de personas, objetos y trayectorias dentro del entorno registrado [6].

En el contexto colombiano, la percepción de inseguridad puede incrementarse hasta en un 35 % dependiendo de la temporada, lo que ha impulsado a muchos ciudadanos y negocios a invertir en sistemas de videovigilancia [7]. Algunos establecimientos cuentan, incluso, con

tecnologías avanzadas que integran inteligencia artificial para la detección de comportamientos sospechosos. Sin embargo, esta no es una opción viable para todos, lo que provoca la brecha tecnológica y limita la efectividad de muchos sistemas de seguridad convencionales.

Frente a esta problemática, surge la siguiente pregunta de investigación: ¿Cómo puede desarrollarse un modelo de inteligencia artificial para mejorar, mediante postprocesado, la calidad y fluidez de videos de vigilancia capturados por sistemas de bajo costo, con el fin de optimizar la extracción de información útil para fines de seguridad?

## **1.2 Justificación**

En muchas ocasiones, las cámaras de videovigilancia no logran grabar videos con la calidad suficiente para identificar claramente lo que sucede en el entorno, ni a las personas o los objetos involucrados. Esto limita mucho su utilidad dentro de un sistema de seguridad, ya sea en espacios públicos, residencias o negocios. Cuando un video no tiene el nivel de detalle necesario, se vuelve complicado avanzar en investigaciones judiciales, aclarar incidentes o incluso saber con certeza qué ocurrió en una situación específica. Por eso, mejorar la calidad del video se vuelve algo clave. Si se logra obtener mejor detalle en las imágenes, los sistemas de seguridad pueden ser muy útiles y efectivos.

Una manera de lograrlo es mediante técnicas de superresolución, las cuales usan modelos de inteligencia artificial para mejorar la calidad de videos que fueron grabados con baja resolución. Gracias a estas técnicas, es posible compensar algunas de las limitaciones que tienen las cámaras por su hardware, y mejorar las grabaciones incluso después de que ya fueron hechas [8]. Con esto, se puede dar un mejor uso a los sistemas de videovigilancia que ya existen, sin necesidad de reemplazarlos, haciendo que sean muy útiles para cuidar a las personas y aclarar lo que pasa en distintos espacios.

### **1.2.1 Beneficios tecnológicos**

Este proyecto busca aportar al desarrollo tecnológico mediante la integración de técnicas de superresolución y aumento de fotogramas por segundo aplicadas a sistemas de videovigilancia. Al combinar visión por computador e inteligencia artificial, se promueve el uso de modelos de aprendizaje automático capaces de mejorar la calidad y fluidez de los videos. Esto representa un avance en el área de la seguridad electrónica, demostrando cómo la tecnología puede potenciar el rendimiento de sistemas ya existentes sin modificar su infraestructura física.

### **1.2.2 Beneficios económicos**

Este proyecto puede generar un impacto económico positivo al permitir que las cámaras de videovigilancia de bajo costo sigan siendo útiles sin necesidad de reemplazarlas. Al mejorar la calidad del video mediante inteligencia artificial, se hace viable el uso de equipos accesibles económicamente, sin comprometer la funcionalidad del sistema de seguridad. Además, como el modelo propuesto puede aplicarse a diferentes entornos sin requerir modificaciones físicas ni actualizaciones costosas de hardware o software, representa una solución escalable y asequible. Esto lo convierte en una alternativa económicamente viable para hogares, negocios o instituciones que ya cuentan con sistemas de videovigilancia básicos.

### **1.2.3 Beneficios sociales**

Este proyecto puede aportar al bienestar social al contribuir con la mejora de los sistemas de videovigilancia, fortaleciendo así la seguridad en espacios públicos y privados. Al ofrecer una mejor calidad de imagen y más detalles en los videos, se facilita el acceso de las autoridades a evidencia audiovisual útil para esclarecer hechos delictivos. Además, al tratarse de una solución basada en inteligencia artificial que no requiere equipos costosos, se promueve una mayor accesibilidad tecnológica.

### **1.2.4 Beneficios institucionales**

La Universidad Francisco de Paula Santander se verá beneficiada ya que servirá como base para futuros proyectos que se relacionen con la aplicación de inteligencia artificial en el mejoramiento de sistemas de cámaras de seguridad, a partir de técnicas de superresolución y aumento de fotogramas por segundo. Esto concuerda con el enfoque del programa de Ingeniería Electrónica dentro de la universidad.

### **1.3 Alcances**

Este proyecto adoptó un enfoque cuantitativo y se orientó al desarrollo de un modelo de inteligencia artificial que mejora la calidad de los videos obtenidos a partir de cámaras de vigilancia con limitaciones de hardware, como baja resolución o poca fluidez. El modelo implementó técnicas de superresolución y aumento de fotogramas por segundo, utilizando un conjunto de videos reales de baja calidad para su entrenamiento y validación. Se logró una mejora visual perceptible que optimiza el análisis de las grabaciones.

El alcance del trabajo comprendió el diseño, entrenamiento y evaluación de un modelo funcional capaz de procesar videos y entregar resultados con mejor nivel de detalle. Estos videos podrán ser muy útiles para la recolección de información en investigaciones judiciales, hechos internos o situaciones que requieran una revisión clara del entorno grabado.

El proyecto se limitó al procesamiento en fase de posproducción, sin realizar modificaciones físicas al hardware de las cámaras de videovigilancia. Asimismo, el modelo fue evaluado en entornos controlados y mediante bases de datos públicas, sin incluir su despliegue en sistemas comerciales en tiempo real.

## 1.4 Limitaciones

El desarrollo del modelo de inteligencia artificial estuvo condicionado por la disponibilidad de bases de datos de videos reales de vigilancia, lo que limitó la diversidad de escenarios evaluados, particularmente en condiciones extremas de iluminación, compresión y ruido digital.

Asimismo, el entrenamiento y validación del modelo dependieron de los recursos computacionales disponibles de la universidad, especialmente en términos de capacidad de procesamiento gráfico (GPU) y memoria, lo cual restringió el tamaño del conjunto de datos utilizado y el número de iteraciones de entrenamiento posibles.

Finalmente, el sistema fue implementado y evaluado bajo un esquema de procesamiento offline, sin integración directa en plataformas de monitoreo en tiempo real, por lo que su aplicabilidad inmediata en sistemas operativos de videovigilancia requiere etapas adicionales de optimización e implementación.

## **2. Objetivos**

A continuación, se presentan los respectivos objetivos para solucionar la problemática planteada anteriormente.

### **2.1 Objetivo General**

Desarrollar un modelo de inteligencia artificial basado en técnicas de superresolución y transformadores visuales para escalar la calidad y fluidez de videos de videovigilancia.

### **2.2 Objetivos Específicos**

- Preprocesar una base de datos de videos de cámaras de seguridad con distintos niveles de calidad, resolución y condiciones de iluminación, garantizando su adecuación para el entrenamiento y validación del modelo de inteligencia artificial.
- Diseñar un modelo de inteligencia artificial basado en transformadores visuales y técnicas de superresolución, con el propósito de mejorar la calidad de los videos mediante la optimización de la resolución y la fluidez.
- Entrenar el modelo de inteligencia artificial utilizando la base de datos seleccionada, aplicando estrategias de optimización y ajuste de hiperparámetros para mejorar su desempeño en la reconstrucción y realce de videos.
- Validar el modelo desarrollado mediante métricas cuantitativas como PSNR y SSIM, junto con evaluaciones cualitativas basadas en percepción visual, y comparar los resultados obtenidos con los de enfoques tradicionales de mejora de video.

### 3. Marco Referencial

#### 3.1 Antecedentes

En los últimos años, el uso de inteligencia artificial para el procesamiento y mejoramiento de imágenes y videos ha tenido un crecimiento significativo, especialmente en aplicaciones relacionadas con seguridad y videovigilancia. Dentro de estas aplicaciones, destacan técnicas como la superresolución y el aumento de fotogramas, las cuales permiten optimizar la calidad visual del contenido capturado por cámaras, incluso cuando estas presentan limitaciones de hardware.

Para este proyecto se han considerado antecedentes a nivel regional, nacional e internacional, que incluyen investigaciones enfocadas en la mejora de video mediante redes neuronales, modelos de superresolución aplicados a sistemas de vigilancia, y desarrollos recientes que integran arquitecturas basadas en transformadores para el procesamiento de imágenes. Estos trabajos permiten establecer un punto de partida técnico y académico, así como identificar las principales oportunidades de mejora que se abordan en la presente propuesta.

##### 3.1.1 Referentes regionales

**Sistema De Corrección De Ruido En Imágenes De Conducción Asistida Implementando Redes Neuronales De Tipo Autoencoder.** En esta investigación se desarrolló un sistema para corregir el ruido presente en imágenes utilizadas para los procesos de conducción asistida, mediante redes neuronales de tipo autoencoder. Los resultados de este trabajo mostraron la efectividad del modelo propuesto, que presentó un mayor número de parámetros que el modelo inicial. El trabajo destaca la importancia de utilizar recursos de software libre, en los cuales se encuentra, principalmente, Python y sus librerías para procesamiento de imágenes y redes neuronales, así como la compatibilidad con plataformas como Google Colab para acelerar el



entrenamiento mediante GPUs. El sistema desarrollado se denominó DCAEAD y demostró ser especialmente efectivo en la corrección de ruido Salt & Pepper, con un comportamiento ligeramente inferior frente al ruido Gaussiano [9].

**DUnet-MI Corrección de ruido en imágenes médicas implementando redes neuronales artificiales tipo autoencoder.** En este artículo se desarrolla un modelo de aprendizaje profundo llamado DUnet-MI para corregir diferentes tipos de ruido en imágenes médicas, como Rayos X, Tomografía Computarizada y Resonancia Magnética. DUnet-MI, una adaptación del modelo Unet, se enfocó en ruido Gaussiano y Salt & Pepper, logrando mejoras significativas en las métricas PSNR y SSIM. En pruebas con 200 imágenes, alcanzó promedios de hasta 29,39 dB en PSNR y 0,890 en SSIM para ruido Gaussiano, y 38,57 dB en PSNR y 0,928 en SSIM para ruido sal y pimienta. Este modelo, desarrollado con recursos de software libre y acelerado con GPUs, demostró ser efectivo y replicable, contribuyendo al mejoramiento de la calidad de imágenes médicas para un diagnóstico más preciso [10].

### 3.1.2 Referentes nacionales

**Súper resolución aplicada a imágenes satelitales.** En este artículo se propone una técnica de superresolución para mejorar la calidad de imágenes satelitales utilizando una formulación matemática propia, sin utilizar algún modelo de inteligencia artificial. A partir de las imágenes obtenidas, la validación se realizó mediante una comparación visual entre la imagen original y la imagen mejorada, sin el uso de métricas como PSNR o SSIM. Uno de los desafíos mencionados en el estudio fue la disponibilidad de las imágenes satelitales, ya que estas solo pueden obtenerse cada varios días o semanas. Esto dificultó la posibilidad de comparar los resultados mejorados con imágenes recientes del mismo lugar [11]. Aunque el enfoque del artículo es diferente,

representa un antecedente relevante que demuestra la aplicabilidad de la superresolución en entornos con imágenes limitadas.

**Zonificación automática basada en imágenes de súper resolución.** En este proyecto, se desarrolla una metodología para mejorar imágenes capturadas por drones y realizar zonificación geográfica automática. Para ello, se utilizan múltiples técnicas de superresolución, entre ellas SISR, MISR, filtros de Wiener, e incluso algoritmos de reconstrucción robusta, aplicadas sobre un banco de imágenes reales. Posteriormente, el trabajo incorpora una estrategia de Deep learning basada en la red neuronal Pix2Pix, con el fin de realizar segmentación semántica de las imágenes mejoradas, identificando zonas urbanas, áreas verdes, cuerpos de agua y carreteras. Esta combinación de técnicas permite optimizar el uso del terreno para planificación urbana, monitoreo ambiental o aplicaciones agrícolas. El estudio complementa su enfoque con un análisis cuantitativo de métricas como la nitidez, concluyendo que la mejor combinación es la interpolación lineal modificada junto con la red Pix2Pix, alcanzando un rendimiento visual significativamente superior al resto de métodos evaluados [12].

**Superresolución Angular de Campos de Luz a partir de Aprendizaje Profundo de Máquina.** En este trabajo de investigación propone un método para mejorar la resolución angular en campos de luz mediante técnicas de aprendizaje profundo. Su enfoque principal se basa en redes neuronales capaces de aprender representaciones complejas de la información visual, permitiendo reconstruir imágenes con mayor nivel de detalle a partir de datos limitados. Los resultados obtenidos en este trabajo demuestran que el modelo desarrollado es capaz de incrementar la calidad de los campos de luz al mejorar la resolución angular, evidenciando el potencial del aprendizaje profundo para resolver limitaciones en la captura de imágenes [13].

**Superresolución basada en una única imagen para imágenes hiperespectrales.** Este artículo propone un método de superresolución aplicado a imágenes hiperespectrales (HSI), las cuales son fundamentales en aplicaciones de teledetección, exploración de minerales e imágenes espaciales. El algoritmo implementado integra información espacial y espectral en un marco unificado, utilizando muestreo espacio-espectral y un interpolador tridimensional, lo que permite obtener una reconstrucción más precisa de alta resolución. Como resultado, se alcanzaron mejoras de hasta 2 dB en términos de PSNR frente a métodos tradicionales [14]. Este estudio evidencia la importancia de la superresolución constituyendo un referente metodológico aplicable a otros campos como el procesamiento de videos en cámaras de vigilancia.

**Mejorando el reconocimiento facial en sistemas de vigilancia mediante super-resolución embebida.** En este proyecto se plantea la integración de técnicas de superresolución en sistemas de videovigilancia para mejorar la precisión del reconocimiento facial. Mediante el uso del modelo ESPCN (Efficient Sub-pixel Convolutional Network), los autores lograron aumentar progresivamente la resolución de imágenes faciales capturadas por cámaras de baja calidad, alcanzando un desempeño superior al de los métodos de interpolación convencionales. Además, el modelo fue implementado en un sistema embebido NVIDIA Jetson TX2, lo que permitió comprobar su aplicabilidad en contextos de vigilancia en tiempo real [15]. Este antecedente resulta significativo para el presente proyecto, ya que confirma la utilidad de la superresolución basada en redes neuronales en escenarios de seguridad, donde la calidad del video es determinante para la identificación de personas y la generación de evidencia confiable.

### 3.1.2 Referentes internacionales

**Súper-Resolución con Redes Convolucionales Adversariales.** El enfoque principal sobre este proyecto está en el uso de inteligencia artificial, especialmente en las Redes Generativas

Adversariales (GAN), una tecnología que combina dos redes neuronales para generar imágenes con mejor nivel de detalle. El objetivo del estudio fue de proponer un modelo capaz de aplicar estas técnicas, y exploró su uso en distintas áreas como la medicina, las imágenes satelitales y la computación. Durante el desarrollo del proyecto, se usaron librerías como TensorFlow, Numpy, PIL y Matplotlib, y se enfrentaron varios desafíos, principalmente relacionados con el rendimiento del sistema [16]. Este trabajo es importante para la presente propuesta porque demuestra cómo la inteligencia artificial puede mejorar imágenes de baja calidad, lo cual también es útil en sistemas de videovigilancia, donde muchas veces las grabaciones no tienen suficiente detalle.

**Estudio de Viabilidad para la Aplicación de una Técnica de Super-Resolución en Imagen SPECT de Pequeños Animales.** Este artículo tuvo como objetivo evaluar si es viable aplicar técnicas de superresolución en imágenes generadas por un tomógrafo SPECT, utilizado para estudiar pequeños animales en el área médica. El enfoque se basa en una técnica que no necesita estimar el movimiento entre imágenes, ya que el propio sistema permite desplazar los detectores y el objeto en pequeñas fracciones. El algoritmo empleado, basado en el análisis de movimiento para el mejoramiento de imagen, logró mejorar la resolución hasta en un 15%. Uno de los principales desafíos fue el ruido en las imágenes: ya que el resultado final de la imagen, también sale reflejado el ruido. Por esta razón, el artículo recomienda aplicar filtros adicionales durante el postprocesamiento para limpiar la imagen. Para validar el rendimiento del algoritmo, se utilizó una métrica conocida como FWHM (Full Width at Half Maximum), común en la evaluación de nitidez en imágenes médicas [17]. Aunque su aplicación fue en medicina, la lógica detrás del proceso puede utilizarse a sistemas de videovigilancia, donde también se necesita obtener más detalle a partir de imágenes de baja calidad.

**Video Super-Resolution Transformer.** Este proyecto aborda el desafío de reconstruir videos en alta resolución a partir de videos en baja calidad, utilizando transformadores para esta tarea. Las personas encargadas del proyecto encontraron limitaciones en el diseño tradicional de los bloques de Transformer, ya que no aprovechan la localidad de los datos ni la correlación entre los fotogramas. Para abarcar esta limitante, propusieron una capa de autoatención espacio temporal y un módulo de alineación basado en flujo óptico bidireccional, lo que permite mejorar la consistencia de las secuencias y la calidad visual de los videos reconstruidos. Los experimentos realizados sobre múltiples bases de datos demostraron que este enfoque logra resultados superiores frente a métodos previos, mostrando el potencial de los transformadores como alternativa prometedora para la superresolución de video [18].

**Frame-Recurrent Video Super-Resolution.** Este estudio propone un marco recurrente de superresolución de video que aprovecha la información de los cuadros anteriores para generar los siguientes en alta resolución. A diferencia de los métodos tradicionales que procesan cada volumen de fotogramas de manera independiente, este enfoque reutiliza el resultado previamente generado, reduciendo el costo computacional y mejorando la coherencia temporal en las secuencias. Después de realizar varias pruebas se pudo observar que el modelo recurrente no solo es más eficiente, sino que también supera a otros métodos en calidad visual y métricas de evaluación [19]. Este estudio resulta importante para el presente proyecto, ya que demuestra la importancia de mantener la continuidad entre fotogramas al mejorar videos de vigilancia.

**Detail-revealing Deep Video Super-resolution.** Este proyecto introduce un marco basado en aprendizaje profundo para mejorar la calidad de video, integrando una capa de compensación de movimiento a nivel sub-píxel (SPMC) que permite alinear los fotogramas de manera precisa. Como resultado, el modelo es capaz de extraer y fusionar detalles de múltiples cuadros, logrando

resultados visuales y métricos superiores a los obtenidos por métodos tradicionales. Además, su diseño escalable le permite adaptarse a diferentes resoluciones y volúmenes de fotogramas de entrada [20].

### **3.2 Marco Teórico**

Dentro de esta sección se evidencian los fundamentos necesarios para sustentar el desarrollo de este proyecto, las fuentes que se utilizan son de carácter investigativo y que poseen relación con el área de inteligencia artificial, procesamiento de imágenes, videovigilancia y técnicas de superresolución.

#### **3.2.1 Inteligencia Artificial**

La inteligencia artificial es una herramienta moderna que se ha podido aplicar en diversos sectores tecnológicos y empresariales, y que también forma parte del día a día de las personas. Es capaz de razonar de forma similar a la inteligencia humana, a partir de un aprendizaje profundo basado en gran cantidad de información y muy eficiente [21]. Actualmente, su desarrollo avanza con rapidez gracias a la mejora de los algoritmos, la evolución de tecnologías de procesamiento y la amplia disponibilidad de datos. Esto ha permitido su integración en las áreas como la medicina, la educación y la vigilancia. Uno de sus usos más comunes es la automatización de procesos con una mayor eficiencia y menor tasa de error en comparación con el trabajo humano. Y, además, se destaca por su capacidad para reconocer y generar imágenes a partir de información o datos proporcionados [22].

##### **3.2.1.1 Redes neuronales**

Una red neuronal artificial (RNA) es un modelo computacional que está inspirado en el funcionamiento básico de una neurona del cerebro humano. Estas se componen de tres capas: la primera, es la capa de entrada, donde se reciben los datos. La segunda capa, es una capa oculta

que sirve como intermediaria entre la entrada y salida, y esta se constituye en el proceso de combinar, transformar y filtrar información importante que se obtenga de la capa anterior. Y la tercera capa, que es la salida, es el resultado final tras el procesamiento de la capa oculta [23].




Figura 1. Esquema de una red neuronal artificial. Tomado de [23].

### 3.2.1.2 Transformadores visuales

Son herramientas que permiten extraer información de una imagen mediante su división en pequeñas porciones llamadas parches, que son pequeñas secciones en las que se divide la imagen para que el modelo pueda procesar y entender el contexto o escenario de la imagen. También, a partir de estos parches, el modelo puede aprender patrones relevantes utilizando técnicas de aprendizaje profundo. Estas tecnologías se pueden aplicar en diversos contextos como la detección de objetos, el reconocimiento de acciones dentro de escenas, la mejora de la calidad de las imágenes y entre otros, adaptándose a diferentes necesidades según el entorno o problema que se desee resolver [24].

### 3.2.1.3 Aprendizaje profundo (Deep Learning)

El Deep Learning es una subrama del Machine Learning, se distingue por su capacidad para analizar grandes volúmenes de datos no estructurados mediante redes neuronales profundas. Estas redes están compuestas por múltiples capas ocultas que permiten detectar patrones complejos. Mientras que el Machine Learning suele emplearse en tareas con información más simples, como texto o tablas, el Deep Learning permite trabajar con información más variada,

como imágenes, audio o video, gracias a su arquitectura jerárquica que simula el aprendizaje humano y que puede aprender directamente de los datos proporcionados [25].

### **3.2.2 Procesamiento de imágenes**

El procesamiento de imágenes consiste en la aplicación de algoritmos para crear, mejorar, transmitir o visualizar imágenes digitales. Entre sus aplicaciones más relevantes se encuentran la de mejorar de la claridad, la eliminación de ruido, la extracción de información a partir de señales captadas por sensores y, de forma cotidiana, enviar y recibir imágenes a través de redes [26].

#### **3.2.2.1 Superresolución**

La superresolución es una técnica utilizada para mejorar imágenes que presentan detalles difusos, falta de nitidez o baja visibilidad debido a su reducida resolución. El proceso consiste en que el algoritmo analice la imagen original, para, después, descomponerla en componentes más pequeños y reconstruirla con un mayor nivel de detalle, incrementando así su escala y calidad visual. Según una revisión reciente, los métodos de superresolución abarcan tanto enfoques tradicionales como técnicas basadas en aprendizaje profundo, las cuales han demostrado superar ampliamente la calidad de reconstrucción en imágenes y videos [27].

#### **3.2.2.2 GAN**

Las redes generativas antagónicas (GAN, por sus siglas en inglés) están compuestas por dos modelos de inteligencia artificial que se entrenan simultáneamente. Un modelo denominado generador, se encarga de producir datos falsos a partir de patrones aprendidos, mientras que el otro modelo llamado discriminador, tiene como objetivo diferenciar estos datos falsos de los ejemplos reales. El término *generativo* hace referencia a la capacidad de crear nuevos datos. Y el termino *antagónicas* describe la dinámica competitiva entre estos dos modelos, en la que se



desafían constantemente para mejorar su rendimiento. Esta retroalimentación continua permite que el generador alcance un nivel en el que sus resultados sean casi indistinguibles de los reales. Las GAN se utilizan ampliamente en tareas como la superresolución, la transformación de estilos y la generación sintética de imágenes [28], [29].

### **3.2.2.3 SRGAN**

Las redes SRGAN (Super-Resolution Generative Adversarial Network), es un método capaz de generar imágenes de alta resolución con un nivel de detalle y realismo superior al de los métodos tradicionales de superresolución. La arquitectura propuesta combina un generador basado en redes residuales profundas que son las ResNet. Las ResNet (Redes Residuales) son arquitecturas de redes neuronales que aprenden funciones residuales, lo que permite construir modelos mucho más profundos sin que se degrade la señal o el rendimiento. Gracias a sus conexiones de salto, estas redes facilitan el entrenamiento y mejoran la precisión en tareas como la clasificación de imágenes y la detección de objetos [30]. Esto en conjunto con un discriminador entrenado para diferenciar imágenes reales de las generadas, incorporando además una pérdida perceptual calculada a partir de las características extraídas por una red VGG preentrenada, el cual se basa en una red de aprendizaje profundo, parecido a la ResNet, pero su aprendizaje es mediante transferencia, es más largo, pero evita volver a entrenarlo [31]. Esta combinación permite reconstruir texturas finas y detalles, logrando que las imágenes ampliadas resulten más realistas a la percepción humana. En sus experimentos, los autores demostraron que SRGAN superaba a métodos de superresolución ya existentes, ofreciendo un aspecto visual más cercano al de las imágenes originales [32].

#### 3.2.2.4 ESRGAN

ESRGAN (Enhanced Super-Resolution Generative Adversarial Network) representa una mejora frente al SRGAN, aumentando la calidad perceptual de las imágenes. En su diseño se reemplazan los bloques residuales clásicos (ResNet), por Residual-in-Residual Dense Blocks (RRDB), lo que facilita la captura de características visuales finas mientras se mejora la estabilidad del entrenamiento. Además, implementan un discriminador relativista, capaz de diferenciar si una imagen es real o falsa y validar cuál de dos imágenes (real vs. falsa) parece más real, mejorando la fidelidad y el detalle. Por último, modifican la función de pérdida perceptual empleando características antes de la activación, lo cual favorece la consistencia del brillo y la recuperación precisa de texturas [33].

#### 3.2.3 Interpolación de fotogramas (Frame Interpolation)

La interpolación de fotogramas es una técnica utilizada para generar imágenes entre fotogramas reales de un video, con el fin de aumentar su tasa de fotogramas y mejorar la fluidez de la grabación. Este proceso se había basado en métodos como el cálculo de flujo óptico, los cuales presentan limitaciones, pero actualmente se está empleando arquitecturas *transformer* para que se pueda modelar dependencias globales entre regiones de la imagen, logrando así una mayor coherencia espacial y temporal en los fotogramas generados. Además, incorporan un módulo de refinamiento que optimiza áreas de alta complejidad, como bordes y objetos en rápido movimiento. Esta herramienta ofrece aplicaciones potenciales en la restauración de material audiovisual como la mejora de videos capturados a baja velocidad y la optimización de experiencias visuales en entornos interactivos [34].

### **3.2.3.1 RIFE (Real Time Intermediate Flow Estimation)**

RIFE es un método de interpolación de fotogramas en tiempo real que destaca por su eficiencia y precisión. Logra interpolar fotogramas de manera significativamente más rápida que otros métodos como SuperSloMo o DAIN, y mantiene una calidad visual comparable o superior. Este método utiliza una red neuronal llamada IFNet, que realiza una estimación directamente en el flujo intermedio entre dos fotogramas. Además, gracias a su codificación temporal, puede interpolar en tiempos arbitrarios, ofreciendo flexibilidad para aplicaciones en los videos [35].

### **3.2.4 Google Colab**

Google Colab es una herramienta gratuita ofrecida por Google para el desarrollo de proyectos en lenguaje Python. Como proyectos se tienen académicos como la solución de ecuaciones matemáticas y la generación de gráficos, es ampliamente utilizada en proyectos de inteligencia artificial, aprendizaje profundo y visión por computadora. Esta herramienta, además de poder ser ejecutada desde un navegador, ofrece acceso a GPU y TPU para la aceleración de cálculos, lo que permite entrenar y probar modelos de IA, sin necesidad de contar con una computadora de alto rendimiento [36].

### **3.2.5 Validación y métricas**

En los sistemas de procesamiento y mejoramiento de imágenes y video es importante contar con ciertas herramientas que permitan evaluar la calidad de los resultados obtenidos. La validación se realiza mediante el uso de métricas cuantitativas que comparan la similitud entre las imágenes originales y las mejoradas o reconstruidas, con el fin de determinar el desempeño del modelo utilizado. Estas métricas permiten medir tanto la fidelidad visual como la preservación de la estructura y los detalles, otorgando una base sólida para contrastar distintos enfoques y garantizar la confiabilidad de los resultados [37].

### 3.2.5.1 PSNR (Peak Signal to Noise Ratio)

El PSNR es una métrica utilizada para evaluar la calidad de imágenes y videos reconstruidos o comprimidos. Lo que realiza esta métrica es comparar una imagen procesada con su versión original, y se basa en el cálculo del error cuadrático medio (MSE) y se expresa en decibelios (dB), y  $MAX_I$  es el valor máximo posible de un píxel en la imagen. El valor más alto indica que la imagen procesada conserva mayor fidelidad con respecto a la original. La ecuación del PSNR se define como [38]:

$$PSNR = 20 * \log_{10}\left(\frac{MAX_I}{\sqrt{MSE}}\right)$$

Esta métrica es útil en aplicaciones como la superresolución, la restauración de imágenes y la compresión de video, aunque presenta la limitación de que no siempre se pueda reflejar de manera precisa la percepción visual humana [39].

### 3.2.5.2 SSIM (Structural Similarity Index Measure)

El índice de similitud estructural (SSIM, por sus siglas en ingles), es una medida utilizada para evaluar la calidad de las imágenes reconstruidas o comprimidas. A diferencia de la evaluación PSNR, el SSIM evalúa en una imagen tres aspectos: luminosidad, contraste y estructura. Esta evaluación permite validar que tan cercana es la imagen procesada a la percepción visual que tendría una persona [40].

## 3.3 Marco Legal

En esta sección especifica todas las leyes y normativas que se tendrán en cuenta a la hora de llevar a cabo el proyecto relacionado a la programación y desarrollo del modelo, esto con el fin de cumplir el marco de la legalidad del país en el cual se llevará a cabo el desarrollo de este proyecto. En la tabla 1 se presenta la normatividad para la creación de algoritmos dentro de la República de Colombia.

Tabla 1. Normativa sobre la creación de algoritmos en Colombia.

| <b>Normas que aplican al desarrollador y uso del software</b>          |                                                         |           |                |
|------------------------------------------------------------------------|---------------------------------------------------------|-----------|----------------|
|                                                                        | Norma                                                   | Licencias | Bases de Datos |
| Ley 603 de 2000                                                        | Distribución de Licencias y Derechos de Autor           | X         |                |
| Ley 1273 de 2009                                                       | Manipulación de Bases de Datos en Sistemas Informáticos |           | X              |
| Ley 23 de 1982                                                         | Ley de Protección de los Derechos de Autor              | X         | X              |
| <b>Normas que aplican al manejo de datos e información audiovisual</b> |                                                         |           |                |
| Ley 1581 de 2012                                                       | Protección de Datos Personales / Habeas Data            |           | X              |
| Ley 1801 de 2016                                                       | Código de Policía                                       |           | X              |

### 3.3.1 Ley 603 de 2000: Distribución de Licencias y Derechos de Autor

Esta ley establece la obligación para las sociedades comerciales de reportar en sus informes de gestión el cumplimiento de las normas relativas a la propiedad intelectual del software. Su finalidad es asegurar que los programas utilizados o distribuidos cuenten con las licencias correspondientes [41].

### 3.3.2 Ley 1273 de 2009: Manipulación de Bases de Datos en Sistemas Informáticos

Esta ley establece nuevos tipos de penales relacionados con la protección de la información y los datos en sistemas informáticos. También aplica sanciones para quienes accedan, utilicen, modifiquen o manipulen de manera no autorizada bases de datos y sistemas digitales. Con esto se podrá garantizar así la seguridad y confidencialidad de la información [42].

### 3.3.3 Ley 23 de 1982: Ley de Protección de los Derechos de Autor

Esta ley regula los derechos de autor en Colombia, estableciendo la protección legal para obras literarias, artísticas y científicas, incluyendo documentos escritos, programas de cómputo,

imágenes y material audiovisual. Para el entrenamiento del modelo y respetando las propiedades intelectuales, únicamente podrán emplearse bases de datos o recursos que sean de libre acceso, con licencias abiertas, o que cuenten con la debida autorización para su utilización [43].

### **3.3.4 Ley 1581 de 2012: Protección de Datos Personales / Habeas Data**

Esta ley establece disposiciones generales para la protección de datos personales en Colombia, garantizando el derecho fundamental de todas las personas a conocer, actualizar y rectificar la información que se recoja sobre ellas en bases de datos o archivos. En ese sentido, el manejo de los datos deberá realizarse respetando los principios de legalidad, finalidad, libertad y confidencialidad, asegurando que cualquier material empleado cuente con la debida autorización o provenga de repositorios de libre acceso [44].

### **3.3.5 Ley 1801 de 2016: Código de Policía**

Esta ley, también conocida como el Código Nacional de Seguridad y Convivencia Ciudadana, regula aspectos relacionados con el uso de tecnologías de vigilancia y control en el espacio público. Esta normativa establece parámetros para el uso responsable de estos dispositivos, garantizando que la información recolectada sea utilizada únicamente con fines de seguridad, prevención o investigación, y que no se vulnere la intimidad de las personas ni se dé un uso indebido a los datos obtenidos [45].

#### 4. Diseño Metodológico

El desarrollo del sistema propuesto se estructuró bajo una arquitectura modular orientada al mejoramiento de videos de videovigilancia de baja calidad. La implementación se dividió en cuatro fases principales: definición y diseño, desarrollo técnico, ejecución y entrenamiento y validación y cierre.

A diferencia de un enfoque secuencial basado únicamente en actividades, el presente capítulo describe de manera técnica la construcción del modelo, detallando la arquitectura utilizada, los parámetros de entrenamiento y las decisiones de ingeniería adoptadas durante el desarrollo.

#### DIAGRAMA DE METODOLOGÍA DEL PROYECTO DE TESIS




Figura 2. Ruta de actividades. Fuente: Elaboración propia.

##### 4.1 Arquitectura del sistema propuesto

El sistema se diseñó bajo un enfoque de postprocesado modular, integrando redes neuronales profundas para resolver dos limitaciones críticas de la videovigilancia: la baja definición y la falta de fluidez temporal. La arquitectura propuesta opera de manera secuencial, donde cada módulo cumple una función específica dentro del flujo de mejora visual.

#### **4.1.1 Diagrama general del flujo de trabajo**

El flujo de trabajo (pipeline) del sistema comienza con la recepción de secuencias de video degradadas. El proceso se estructuró en dos etapas principales: primero, el video ingresa al módulo de superresolución para el realce de detalles y, posteriormente, los fotogramas resultantes son procesados por el módulo de interpolación para aumentar la tasa de cuadros por segundo (FPS). Esta configuración asegura que la mejora en la resolución no comprometa la coherencia temporal de la grabación final.

#### **4.1.2 Diagrama general del flujo de trabajo**

Para el escalamiento visual, se implementó una arquitectura basada en transformadores visuales, específicamente diseñada para capturar dependencias de largo alcance en las imágenes de vigilancia. A diferencia de las redes convolucionales tradicionales, este diseño permitió reconstruir texturas finas y bordes nítidos en elementos críticos como rostros y placas vehiculares, incluso bajo condiciones de ruido digital.

#### **4.1.2 Diseño del módulo de interpolación**

El módulo de interpolación se fundamentó en técnicas de estimación de flujo óptico intermedio para generar fotogramas sintéticos de alta fidelidad. Se seleccionó un modelo capaz de analizar el movimiento entre cuadros consecutivos, permitiendo duplicar o triplicar la fluidez del video original. Este diseño resultó vital para suavizar grabaciones de cámaras de bajo costo que suelen operar a bajas tasas de refresco, optimizando así el seguimiento de trayectorias en escenas de seguridad.

### **4.2 Preparación del dataset**

Para el desarrollo de este proyecto, se llevó a cabo un proceso de identificación y adquisición de material audiovisual orientado a cubrir las deficiencias típicas de los sistemas de



videovigilancia de bajo costo. La selección de los datos también se basó en criterios técnicos de utilidad para el entrenamiento de modelos de Inteligencia Artificial.

#### **4.2.1 Fuentes de información y repositorios**

Se realizó una búsqueda en base de datos de acceso público especializadas en seguridad. Se priorizó repositorios que contienen grabaciones reales de cámara de video vigilancia y también de páginas de acceso público que transmiten video en tiempo real, esto con el fin de que el modelo contenga artefacto de compresión y ruidos propios de sensores reales. Y con el fin de cumplir leyes y las normativas colombianas, se verificó las licencias y condiciones de uso de cada fuente de libre acceso para asegurar que el proyecto cumple con los estándares que requiere como son los éticos y legales.

#### **4.2.2 Criterios de inclusión de video**

La selección final del conjunto de datos se fundamentó en la presencia de variables que desafían la calidad visual. Se incluyeron secuencias con las siguientes características:

- **Variabilidad de resolución:** Videos con distintas definiciones base para evaluar la capacidad de escalamiento.
- **Condiciones ambientales y de iluminación:** Se seleccionaron tomas de cambios bruscos de luz, escenas en penumbra y grabaciones de saturación lumínica.
- **Ruido y movimiento:** Se dio prioridad a fragmentos que presentaron ruido digital y movimiento de objetos o personas, factores esenciales para validar tanto la superresolución espacial como la interpolación.

#### **4.3 Caracterización de los datos**

Una vez recolectada la base de datos primaria, se llevó a cabo una fase de análisis y procesamiento técnico para asegurar que el material audiovisual fuera apto para el entrenamiento

de las redes neuronales. Esta etapa garantizó la integridad de los datos y la optimización de los recursos computacionales en la plataforma de desarrollo.

#### 4.3.1 Recolección de videos (Públicos y grabaciones propias en entorno controlado)

Se realizó un proceso de validación manual para filtrar los videos útiles que tuvieran características como pérdida total de paquetes de datos o saturación lumínica extrema.

Posteriormente, las secuencias seleccionadas se clasificaron bajo tres criterios importantes:

- **Resolución nativa:** Segmentación de archivos según su definición original (SD, HD y Full HD) para establecer los niveles de escalamiento necesarios.
- **Nivel de ruido:** Identificación de artefactos digitales y grano ISO presentes en las tomas de baja calidad.
- **Condiciones de iluminación:** Categorización en escenarios diurnos, nocturnos y de interiores con luz artificial.

#### 4.3.2 Preprocesamiento y estandarización

Para facilitar el aprendizaje del modelo, se ejecutó una serie de transformaciones técnicas sobre el conjunto de datos final:

- **Segmentación de fotogramas:** Los videos fueron descompuestos en secuencias de imágenes individuales (fotogramas), permitiendo un procesamiento por lotes más eficiente.
- **Normalización de formatos:** Se estandarizaron todos los archivos a un formato de imagen sin pérdida de información, eliminando inconsistencias entre los diferentes códecs de origen de las cámaras de seguridad.
- **Preservación de artefactos originales.** A diferencia de los métodos de preprocesamiento tradicionales, no se aplicaron filtros de reducción de ruido o

suavizado digital, con el fin de que el modelo de IA aprenda a realizar la reconstrucción y el realce directamente sobre las condiciones reales y degradadas de la videovigilancia.

#### **4.4 Entorno de desarrollo y configuración del entrenamiento**

La implementación técnica y el entrenamiento de los modelos de inteligencia artificial se llevaron a cabo en un entorno de computación en la nube, seleccionado por su capacidad de procesamiento gráfico y flexibilidad para el manejo de librerías de aprendizaje profundo. Esta configuración permitió gestionar conjuntos de datos voluminosos y ejecutar procesos de optimización sin las restricciones del hardware local convencional.

##### **4.4.1 Recursos de hardware**

Para el entrenamiento de las arquitecturas ESRGAN y RIFE, se utilizó la plataforma Google Colab, aprovechando instancias equipadas con unidades de procesamiento gráfico NVIDIA (series T4). El uso de memoria de video dedicada (VRAM) fue fundamental para cargar los tensores de los fotogramas y realizar los cálculos necesarios para el ajuste de los pesos de las redes neuronales.

##### **4.4.2 Marco de trabajo y librerías (Software Stack)**

El desarrollo del modelo se estructuró sobre el lenguaje de programación Python, utilizando las siguientes librerías del ecosistema de la inteligencia artificial:

- AQUÍ IRÍA LAS LIBRERIAS UTILIZADAS
- 2da librería

##### **4.4.3 Configuración de hiperparámetros**

Para garantizar un desempeño óptimo en la reconstrucción visual, el proceso de entrenamiento se basó en una estrategia de optimización iterativa. Se aplicaron ajustes de hiperparámetros como

la tasa de aprendizaje y el tamaño del lote, utilizando las capacidades de aceleración por GPU ofrecidas por Google Colab.

Esta fase de optimización permitió que el modelo ajustara sus predicciones mediante retroalimentación constante, minimizando el error entre el fotograma generado y la referencia de alta calidad. El objetivo final de esta configuración fue asegurar que el sistema no solo mejorara la resolución espacial, sino que también garantizara una transición fluida y natural entre fotogramas, eliminando artefactos visuales derivados del bajo bit-rate original de los videos de vigilancia.

QUEDAMOS AQUÍ PARA EMPEZAR EL CAPITULO 5

## Referencias

- [1] “Inteligencia Artificial - Margaret A. Boden - Google Libros.” Accessed: Mar. 27, 2025.  
[Online]. Available:  
[https://books.google.com.co/books?hl=es&lr=&id=LCnYDwAAQBAJ&oi=fnd&pg=PT3&dq=que+es+la+inteligencia+artificial&ots=dsTowZ9Nl5&sig=8wFnumYE10aMl5PgISme3r2q0uc&redir\\_esc=y#v=onepage&q=que%20es%20la%20inteligencia%20artificial&f=false](https://books.google.com.co/books?hl=es&lr=&id=LCnYDwAAQBAJ&oi=fnd&pg=PT3&dq=que+es+la+inteligencia+artificial&ots=dsTowZ9Nl5&sig=8wFnumYE10aMl5PgISme3r2q0uc&redir_esc=y#v=onepage&q=que%20es%20la%20inteligencia%20artificial&f=false)
- [2] J. D. van Ouwerkerk, “Image super-resolution survey,” *Image Vis Comput*, vol. 24, no. 10, pp. 1039–1052, Oct. 2006, doi: 10.1016/J.IMAVIS.2006.02.026.
- [3] “¿Por qué las cámaras de seguridad tienen mala calidad?” Accessed: Apr. 14, 2025.  
[Online]. Available: <https://sobotzo.com/por-que-las-camaras-de-seguridad-tienen-mala-calidad/>
- [4] “Mala calidad de las imágenes: ¿Por qué las cámaras de seguridad tienen tan baja calidad?” Accessed: Apr. 14, 2025. [Online]. Available:  
<https://www.scienceabc.com/eyeopeners/why-is-the-quality-of-cctv-footage-still-so-low.html>
- [5] “¿Por qué la calidad del CCTV es tan mala? -Solink.” Accessed: Apr. 14, 2025. [Online]. Available: <https://solink.com/resources/industry-insights/why-is-cctv-quality-so-bad/>
- [6] F. Enrique Pérez Vizcaíno, M. R. Carlos Mena Bravo FACULTAD DE RELACIONES INTERNACIONALES, and E. Y. Seguridad Programa De Especialización En Administración De La Seguridad Bogota Dc, “SISTEMAS DE VIDEO VIGILANCIA Y SU APOORTE A LA EVOLUCIÓN ESTRATÉGICA DE LA SEGURIDAD CIUDADANA. Presentado por: A”.

- [7] “¿Qué hace el retail colombiano para disminuir los robos en el 2025? - La Nota Económica.” Accessed: Apr. 14, 2025. [Online]. Available: <https://lanotaeconomica.com.co/movidas-empresarial/que-hace-el-retail-colombiano-para-disminuir-los-robos-en-el-2025/>
- [8] D. C. Lepcha, B. Goyal, A. Dogra, and V. Goyal, “Image super-resolution: A comprehensive review, recent trends, challenges and applications,” *Information Fusion*, vol. 91, pp. 230–260, Mar. 2023, doi: 10.1016/J.INFFUS.2022.10.007.
- [9] “GESTIÓN DE SERVICIOS ACADÉMICOS Y BIBLIOTECARIOS CÓDIGO FO-GS-15.”
- [10] A. P. Ardila Sanchez, L. C. Torres Vega, G. F. Contreras Contreras, B. Medina Delgado, and D. Guevara Ibarra, “DUnet-MI Corrección de ruido en imágenes médicas implementando redes neuronales artificiales tipo autoencoder,” *Investigación e Innovación en Ingenierías*, vol. 12, no. 2, Jul. 2024, doi: 10.17081/invinno.12.2.6786.
- [11] “Vista de Súper resolución aplicada a imágenes satelitales”.
- [12] E. Mauricio Cascavita Ríos and J. Andrés Baldion Góngora, “Zonificación automática basada en imágenes de súper resolución.” [Online]. Available: [https://ciencia.lasalle.edu.co/ing\\_automatizacion/784](https://ciencia.lasalle.edu.co/ing_automatizacion/784)
- [13] T. De Grado, J. Felipe, J. Hernández, and M. Fernanda Hernández Baena, “Pontificia Universidad Javeriana.”
- [14] “View of Compact spatio-spectral algorithm for single image super-resolution in hyperspectral imaging \_ Ingeniería e Investigación”.
- [15] “Vista de Mejorando el reconocimiento facial en sistemas de vigilancia mediante super-resolución embebida”.

- [16] J. Alcácer López, “TRABAJO FIN DE GRADO Súper-Resolución con Redes Convolucionales Adversariales.”
- [17] J. L. Villena *et al.*, “Estudio de Viabilidad para la Aplicación de una Técnica de Super-Resolución en Imagen SPECT de Pequeños Animales.”
- [18] J. Cao, Y. Li, K. Zhang, and L. Van Gool, “Video Super-Resolution Transformer,” Jul. 2023, [Online]. Available: <http://arxiv.org/abs/2106.06847>
- [19] M. S. M. Sajjadi, R. Vemulapalli, and M. Brown, “Frame-Recurrent Video Super-Resolution.”
- [20] X. Tao, H. Gao, R. Liao, J. Wang, and J. Jia, “Detail-revealing Deep Video Super-resolution \*.”
- [21] “¿Qué es la inteligencia artificial o IA? | Google Cloud.” Accessed: Jul. 13, 2025. [Online]. Available: <https://cloud.google.com/learn/what-is-artificial-intelligence?hl=es-419>
- [22] M. A. M. Álvarez, M. Á. H. Batista, and A. A. Gutiérrez, “La inteligencia artificial en la generación de imágenes: consideraciones desde el diseño, la comunicación y el arte,” *South Florida Journal of Development*, vol. 4, no. 9, pp. 3713–3728, Dec. 2023, doi: 10.46932/sfjdv4n9-028.
- [23] F. Izaurieta and C. Saavedra, “Redes Neuronales Artificiales.”
- [24] Y. Wang, Y. Deng, Y. Zheng, P. Chattopadhyay, and L. Wang, “Vision Transformers for Image Classification: A Comparative Survey,” *Technologies 2025, Vol. 13, Page 32*, vol. 13, no. 1, p. 32, Jan. 2025, doi: 10.3390/TECHNOLOGIES13010032.
- [25] “¿Qué es el deep learning? | IBM.” Accessed: Jul. 15, 2025. [Online]. Available: <https://www.ibm.com/es-es/think/topics/deep-learning>

- [26] “Procesamiento de imágenes digitales - MATLAB & Simulink.” Accessed: Aug. 13, 2025. [Online]. Available: <https://la.mathworks.com/discovery/digital-image-processing.html>
- [27] D. C. Lepcha, B. Goyal, A. Dogra, and V. Goyal, “Image super-resolution: A comprehensive review, recent trends, challenges and applications,” *Information Fusion*, vol. 91, pp. 230–260, Mar. 2023, doi: 10.1016/J.INFFUS.2022.10.007.
- [28] O. J. Reyes Ortiz, M. Mejia, and J. S. Useche Castelblanco, “Técnicas de inteligencia artificial utilizadas en el procesamiento de imágenes y su aplicación en el análisis de pavimentos,” *Revista EIA*, vol. 16, no. 31, pp. 189–207, Jan. 2019, doi: 10.24050/reia.v16i31.1215.
- [29] “¿Qué es una GAN? - Explicación sobre las redes generativas antagónicas - AWS.” Accessed: Aug. 13, 2025. [Online]. Available: <https://aws.amazon.com/es/what-is/gan/>
- [30] “Redes Residuales (ResNet) - Aprendizaje Profundo - GeeksforGeeks.” Accessed: Aug. 13, 2025. [Online]. Available: <https://www.geeksforgeeks.org/deep-learning/residual-networks-resnet-deep-learning/>
- [31] S. Tammina, “Transfer learning using VGG-16 with Deep Convolutional Neural Network for Classifying Images,” *International Journal of Scientific and Research Publications (IJSRP)*, vol. 9, no. 10, p. p9420, Oct. 2019, doi: 10.29322/IJSRP.9.10.2019.P9420.
- [32] C. Ledig *et al.*, “Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network.”
- [33] X. Wang *et al.*, “ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks.” [Online]. Available: <https://github.com/xinntao/ESRGAN>.
- [34] L. Lu, R. Wu, H. Lin, J. Lu, and J. Jia, “Video Frame Interpolation with Transformer.”



- [35] Z. Huang, T. Zhang, W. Heng, B. Shi, and S. Zhou, “Real-Time Intermediate Flow Estimation for Video Frame Interpolation.” [Online]. Available: <https://github.com/megvii-research/ECCV2022-RIFE>
- [36] “How to use Google Colab - GeeksforGeeks.” Accessed: Aug. 19, 2025. [Online]. Available: [https://www.geeksforgeeks.org/websites-apps/how-to-use-google-colab/?utm\\_source=chatgpt.com](https://www.geeksforgeeks.org/websites-apps/how-to-use-google-colab/?utm_source=chatgpt.com)
- [37] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, “Image quality assessment: From error visibility to structural similarity,” *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, Apr. 2004, doi: 10.1109/TIP.2003.819861.
- [38] “PSNR - Wikipedia, la enciclopedia libre.” Accessed: Aug. 19, 2025. [Online]. Available: <https://es.wikipedia.org/wiki/PSNR>
- [39] “Image Quality Computation,” *Universidad de Berkeley*, Accessed: Aug. 19, 2025. [Online]. Available: <http://bmrc.berkeley.edu/courseware/cs294/fall97/assignment/psnr.html>
- [40] U. Sara, M. Akter, M. S. Uddin, U. Sara, M. Akter, and M. S. Uddin, “Image Quality Assessment through FSIM, SSIM, MSE and PSNR—A Comparative Study,” *Journal of Computer and Communications*, vol. 7, no. 3, pp. 8–18, Mar. 2019, doi: 10.4236/JCC.2019.73002.
- [41] “Ley 603 de 2000 - Gestor Normativo - Función Pública.” Accessed: Aug. 20, 2025. [Online]. Available: <https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=13960>

[42] “Ley 1273 de 2009 - Gestor Normativo - Función Pública.” Accessed: Aug. 20, 2025.

[Online]. Available:

<https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=34492>

[43] “Ley 23 de 1982 - Gestor Normativo - Función Pública.” Accessed: Aug. 20, 2025.

[Online]. Available:

<https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=3431>

[44] “Ley 1581 de 2012 - Gestor Normativo - Función Pública.” Accessed: Aug. 20, 2025.

[Online]. Available:

<https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981>

[45] “Ley 1801 de 2016 - Gestor Normativo - Función Pública.” Accessed: Aug. 20, 2025.

[Online]. Available:

<https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=80538>